Challenge Sprint 1

Coleta Automatizada de Dados de Produtos HP em E-commerce (RPA)

FIAP

Conteúdo

Informações do Documento

Projeto:	Challenge Sprint 2025.1 – RPA – 1º semestre		
Equipe:	555677 - Matheus Hungaro Fidelis 556389 - Pablo Menezes Barreto 556984 - Tiago Toshio Kumagai Gibo 554668 - Israel Dalcin 555183 - Danilo Ramalho Silva 556213 - João Vitor Pires da Silva	**Versão do Documento:**	1.0

Histórico de versão

Versão	Data	Revisado por	Descrição	Nome do Arquivo
1.0	15/06	Tiago Toshio Kumagai Gibo	Criação do documento	Challenge Sprint 2025.1 - RPA

FIAP

1. Estratégia de Scraping

- **Site-alvo**:
  Mercado Livre (https://www.mercadolivre.com.br), principal marketplace do Brasil, selecionado por seu grande volume de produtos e avaliações, e por disponibilizar estrutura HTML relativamente estável.

- **Ferramenta**:
  Python 3.8+ com Selenium WebDriver (ChromeDriver) para simular um navegador real, lidar com conteúdo dinâmico e interagir com elementos via JavaScript .

    - Uso opcional de modo headless (comentado em main.py).
    - Para evitar bloqueios e captchas, aplica-se variação de tempo de espera (time.sleep e random.uniform) e limites de páginas/produtos.

2. Fluxo de Navegação e Extração

2.1 Coleta de URLs de Produto (**scrap_list**)

- **Função**: scrap_list(produto, url, driver) em mercadolivre.py.

- **Passos principais**:
  1. driver.get(url) e time.sleep(2) para aguardar carregamento e reduzir risco de bloqueio.
  2. Aceite de banner de cookies clicando em botão com classe cookie-consent-banner-opt-out__action--key-accept.
  3. Localização de <ol class="ui-search-layout"> e, dentro dele, coleta de todos os títulos de produto em h3.poly-component__title-wrapper para extrair a URL via a.get_attribute("href").
  4. Gravação de cada URL na tabela products_url com save_url(produto, url) .
  5. Paginação: encontra botão “Próximo” em .andes-pagination__button--next a, scroll até ele e dispara JavaScript para clicar após 3 s, retornando nova URL de página ou False se não houver próxima página.

2.2 Coleta de Dados do Produto (**scrap_product**)

- **Função**: scrap_product(url, driver) em mercadolivre.py.

- **Dados extraídos**:
    - **Título** e **preço**: meta tag og:title via XPath, separando em "Título – Preço", convertendo

preço para float.
    - **Avaliação média** e **quantidade de avaliações**: elementos em div.ui-review-capability__rating.
      Descrição: texto de p.ui-pdp-description__content.
    - **Especificações técnicas**: itera linhas de <tr> em div.ui-pdp-container__row--technical-specifications, mapeando “marca”, “linha”, “modelo”, “formato de venda”, “conteúdo total em volume”, “rendimento de páginas” e “tipo de cartucho”.
    - **Vendedor**: texto em div.ui-seller-data-header__title-container.

- **Pós-processamento**: marca URL como scraped = 1 na tabela products_url.

- **Persistência**: insere registro em products_data via save_product(...) .

2.3 Coleta de Comentários (scrap_comments)

- **Função**: scrap_comments(id, url, limit, driver) em mercadolivre.py.

- **Fluxo**:
    1. Acessa a página do produto e aguarda carregamento.
    2. Se existir botão “Mostrar mais” (button.show-more-click), clica e troca para iframe #ui-pdp-iframe-reviews.
    3. Laço até limit comentários ou fim: para cada comentário, extrai nota (p.andes-visually-hidden), data (span.ui-review-capability-comments__comment__date) e texto (p.ui-review-capability-comments__comment__content), salvando em products_review via save_review(...).
    4. Atualiza comments_scraped = 1 em products_data .

3. Estrutura Geral do Código

```
.
├── mercadolivre.py      # Lógica de scraping (listas, produtos, comentários)
├── database.py          # Criação e manipulação de SQLite (tabelas e exportação)
├── main.py              # Fluxo de execução: inputs, inicialização do driver e chamadas às funções
├── requirements.txt     # Dependências (selenium, pandas, sqlite3 etc.)
├── readme.md            # Guia de instalação e uso :contentReference[oaicite:3]{index=3}
└── mercadolivre.db      # Banco gerado após execução
```

- **main.py**:

- Solicita ao usuário produto, páginas, produtos e comentários.
- Inicia ChromeDriver com opções configuráveis.
- Executa, na ordem: list(), product(), comments(), e por fim exporta CSVs em outputs/ via database.exportar_tabelas() .

- **database.py**:
  - Tabelas products_url, products_data, products_review.
  - Funções save_url, save_product, save_review, query, exportar_tabelas() (gera CSVs).

- **requirements.txt**:
  - As versões utilizadas de selenium, pandas, sqlite3 (via python-dateutil, urllib3, etc.) .

4. Tabelas do Banco de Dados

4.1 products_ur

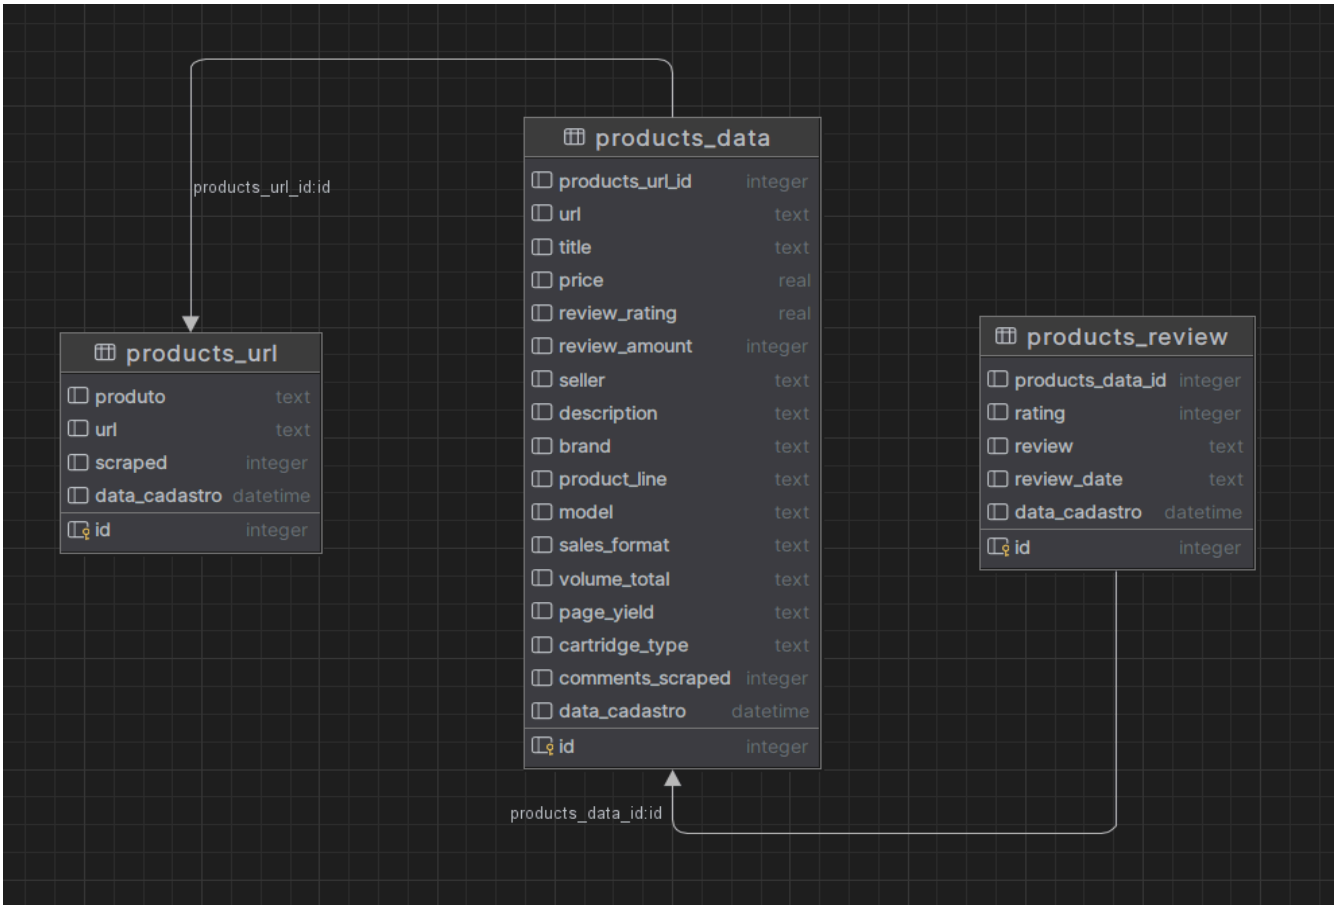

5. Desafios e Soluções

Desafio	Estratégia de Solução
Paginação dinâmica	Uso de time.sleep() + WebDriverWait para garantir que o botão “Próximo” esteja visível antes de scrollar e clicar via execute_script
Conteúdo carregado por JavaScript	Combinação de driver.implicitly_wait(), WebDriverWait e execute_script("scrollIntoView") para forçar renderização de elementos antes da extração
Banner de cookies e pop-ups	Identificação e clique automático em botão de aceite (cookie-consent-banner-opt-out__action--key-accept)
Limite de requisições / bloqueios	Introdução de delays randômicos (random.uniform(3.0, 4.0)) entre acessos para simular comportamento humano.
Elementos ausentes / variações de layout	Tratamento via try/except em cada função de scraping, com logging de exceções e continuidade do fluxo sem interromper toda a execução.

6. Evidências de Execução Bem-sucedida

A seguir, trechos de registros extraídos diretamente do banco de dados (CSV gerados em outputs/):

Amostra de products_url

	id	produto	url	scraped	data_cadastro
1	1	cartucho hp 667 original	https://click1.mercadolivre.com.br/mclics/clicks/e…	1	2025-06-15 04:43:11
2	2	cartucho hp 667 original	https://click1.mercadolivre.com.br/mclics/clicks/e…	1	2025-06-15 04:43:11
3	3	cartucho hp 667 original	https://click1.mercadolivre.com.br/mclics/clicks/e…	1	2025-06-15 04:43:11
4	4	cartucho hp 667 original	https://www.mercadolivre.com.br/cartucho-hp-667-pr…	1	2025-06-15 04:43:11
5	5	cartucho hp 667 original	https://www.mercadolivre.com.br/cartucho-de-tinta-…	1	2025-06-15 04:43:11
6	6	cartucho hp 667 original	https://www.mercadolivre.com.br/cartucho-hp-667-co…	1	2025-06-15 04:43:11
7	7	cartucho hp 667 original	https://www.mercadolivre.com.br/cartucho-de-tinta-…	1	2025-06-15 04:43:11
8	8	cartucho hp 667 original	https://produto.mercadolivre.com.br/MLB-2685036387…	1	2025-06-15 04:43:11
9	9	cartucho hp 667 original	https://www.mercadolivre.com.br/cartucho-de-tinta-…	1	2025-06-15 04:43:12
10	10	cartucho hp 667 original	https://click1.mercadolivre.com.br/mclics/clicks/e…	1	2025-06-15 04:43:12

Amostra de products_data

	id	products_url_id	url	title	price	review_rating	review_amount	seller
1	1	1	https://www.mercadolivre.com.br/cartucho-hp-667xl-pr…	Cartucho Hp 667xl Preto E Color. 02 Preto E 01 Color…	298.5	4.6	80	Park Ecom
2	2	2	https://www.mercadolivre.com.br/hp-667xl-cartucho-de…	HP 667XL Cartucho de tinta Preta 3ym80al	162.63	4.5	82	MVCARTUCHOS4
3	3	3	https://www.mercadolivre.com.br/kit-cartucho-de-tint…	Kit Cartucho De Tinta Hp 667xl Preto + Colorido	270	4.6	80	YUKIINFORMATICA
4	4	4	https://www.mercadolivre.com.br/cartucho-hp-667-pret…	Cartucho HP 667 Preto 2376 2776 6476	66.9	4.7	1,892	OBERO INFORMATICA
5	5	5	https://www.mercadolivre.com.br/cartucho-de-tinta-hp…	Cartucho De Tinta Hp 667 Deskjet Ink Advantage Cor P…	153.1	4.8	1,953	OBERO INFORMATICA
6	6	6	https://www.mercadolivre.com.br/cartucho-hp-667-colo…	Cartucho Hp 667 Colorido 3ym78ab	71.9	4.7	1,892	vanvan
7	7	7	https://www.mercadolivre.com.br/cartucho-de-tinta-hp…	Cartucho De Tinta Hp 667 Cor Preto Do 2 Ml	64.69	4.8	3,384	Eshop
8	8	8	https://produto.mercadolivre.com.br/MLB-2685036387-k…	Kit Cartucho Tinta Original Hp 667 Preto/colorido 23…	154.9	4.7	3,755	OBERO INFORMATICA
9	9	9	https://www.mercadolivre.com.br/cartucho-de-tinta-hp…	Cartucho De Tinta Hp Tricolor 667	68.55	4.7	1,201	Eshop
10	10	10	https://produto.mercadolivre.com.br/MLB-3208197871-k…	Kit Cartucho Hp 667 667xl Deskjet 2776 Preto E Color	199.9	4.4	337	Park Ecom

Amostra de products_review

	id	products_data_id	rating	review	review_date	data_cadastro
1	1	1	Avaliação 4 de 5	As tintas duram pouco, mas acredito que seja um problema da hp e …	13 jun. 2025	2025-06-15 04:49:20
2	2	1	Avaliação 5 de 5	Muito bom,vou voltar a comprar de novo.	29 mai. 2025	2025-06-15 04:49:22
3	3	1	Avaliação 5 de 5	Já sou cliente faz tempo.	28 mai. 2025	2025-06-15 04:49:24
4	4	1	Avaliação 5 de 5	Excelente!.	16 mai. 2025	2025-06-15 04:49:26
5	5	1	Avaliação 5 de 5	Excelente produto.	28 abr. 2025	2025-06-15 04:49:28
6	6	1	Avaliação 5 de 5	Funcionando bem.	25 abr. 2025	2025-06-15 04:49:31
7	7	1	Avaliação 5 de 5	Comprei para guardar, mas verifiquei que todos são genuínos. Esto…	21 abr. 2025	2025-06-15 04:49:33
8	8	1	Avaliação 5 de 5	Bom material.	14 mar. 2025	2025-06-15 04:49:35
9	9	1	Avaliação 5 de 5	Excelente.	16 dez. 2024	2025-06-15 04:49:37
10	10	1	Avaliação 5 de 5	Bom.	19 nov. 2024	2025-06-15 04:49:39

7. Conclusão

Este processo de automação permite replicar de forma robusta a extração de listas, detalhes de produtos e avaliações no Mercado Livre, centralizando dados em um banco SQLite e exportando-os para CSV. A combinação de Selenium com waits explícitos, controle de delays e tratamento de exceções garante resiliência a bloqueios, dinamicidade de conteúdo e variações de layout.

Com esse relatório e o código disponível, outro desenvolvedor pode instalar as dependências, configurar o ChromeDriver e rodar main.py para reproduzir integralmente o pipeline de scraping.

8. Link do Github

https://github.com/tiagotkg/Challenge-Sprint-1-RPA